Codifica dei caratteri ASCII, ANSI, Unicode (UTF)

ASCII – che in inglese si pronuncia æski (**æ** come in f**a**t, **s** come in **s**orry, **k** come in **c**ar, **i** come in happ**y**), ma in italiano viene pronunciato aschi o anche asci – è l'acronimo di American Standard Code for Information Interchange ed è il primo standard introdotto nella codifica dei caratteri di scrittura nel campo dell'IT (Information Techology).

Il **codice ASCII** originario è stato definito nella norma *ISO/IEC 646 - Information technology - ISO 7-bit coded character set for information interchange* [1]. I caratteri sono codificati con `7 bit` cosa che permette di codificare $2^7 = 128$ caratteri numerati da `0` a `127`. I concetti alla base dello standard sono semplici e pratici:
→ codificare i caratteri di controllo ovvero i comandi necessari per gestire da remoto una stampante (originariamente una telescrivente);
→ codificare i caratteri stampabili – lettere, numeri, segni di interpunzione e simboli – di impiego più frequente nella scrittura di un testo.

I caratteri da `0` a `31` sono caratteri di controllo e non sono stampabili. Il carattere `32` corrisponde a uno spazio. I caratteri da `33` a `126` sono caratteri stampabili. Il carattere `127` corrisponde a `Delete` (ed è equivalente a `Backspace`).

Questo è il set di caratteri ASCII originario altrimenti noto come **set di caratteri ASCII di base**:

Codice	Simbolo	Codice	Carattere	Codice	Carattere	Codice	Carattere
0	NUL	32		64	@	96	`
1	SOH	33	!	65	A	97	a
2	STX	34	"	66	B	98	b
3	ETX	35	#	67	C	99	c
4	EOT	36	$	68	D	100	d
5	ENQ	37	%	69	E	101	e
6	ACK	38	&	70	F	102	f
7	BEL	39	'	71	G	103	g
8	BS	40	(	72	H	104	h
9	TAB	41	)	73	I	105	i
10	LF	42	*	74	J	106	j
11	VT	43	+	75	K	107	k
12	FF	44	,	76	L	108	l
13	CR	45	-	77	M	109	m
14	SO	46	.	78	N	110	n
15	SI	47	/	79	O	111	o
16	DLE	48	0	80	P	112	p
17	DC1	49	1	81	Q	113	q
18	DC2	50	2	82	R	114	r
19	DC3	51	3	83	S	115	s
20	DC4	52	4	84	T	116	t
21	NAK	53	5	85	U	117	u
22	SYN	54	6	86	V	118	v
23	ETB	55	7	87	W	119	w
24	CAN	56	8	88	X	120	x
25	EM	57	9	89	Y	121	y
26	SUB	58	:	90	Z	122	z
27	ESC	59	;	91	[	123	{
28	FS	60	<	92	\	124	|

29	GS	61	=	93	]	125	}
30	RS	62	>	94	^	126	~
31	US	63	?	95	_	127	

Questi sono i caratteri stampabili del set di caratteri ASCII di base:

```
!"#$%&'()*+,-./0123456789:;<=>?
@ABCDEFGHIJKLMNOPQRSTUVWXYZ[\]^_`abcdefghijklmnopqrstuvwxyz{|}~
```

Di fatto il set di caratteri ASCII di base riflette il modo in cui i caratteri sono scritti su (e possono essere riletti da) un foglio di carta scritto con una macchina da scrivere, impiegando un set di caratteri/codice universalmente riconosciuto. Non solo: della macchina da scrivere il codice ASCII conserva, ad esempio, il comando `LF` (Line Feed) che fa avanzare il foglio alla riga successiva, e il comando `CR` (Carriage Return) che riporta il carrello della macchina da scrivere (virtuale) all'inizio della riga. Anche se la macchina da scrivere è stato oramai da decenni sostituita da PC, word processor e stampante, è da questa che sono derivati i concetti e questo *standard minimo di base*.

Gli altri set di caratteri che vediamo ora hanno progressivamente esteso il set di caratteri ASCII di base con set di caratteri aggiuntivi, con l'obiettivo di includere tutti i caratteri di tutte le lingue (cosa inimmaginabile via hardware, con un dispositivo meccanico come la macchina da scrivere, ma senza sostanziali problemi via software).

Il primo nato allo scopo di estendere il set di caratteri ASCII di base è stato il **set di caratteri ANSI** (acronimo di American National Standard Institute) nel quale i caratteri sono codificati con `8 bit` (`1 byte`) cosa che permette di codificare $2^8 = 256$ caratteri numerati da `0` a `255`. Il set di caratteri ANSI prevedeva due sottoinsiemi:
→ il set di caratteri ASCII di base (caratteri numerati da `0` a `127`) visto sopra;
→ il set di caratteri ASCII esteso (caratteri numerati da `128` a `255`).

Purtroppo per i caratteri da `128` a `255` del **set di caratteri ASCII esteso** non si è stabilito subito un accordo e questo ha determinato la nascita di differenze tra il successivo set internazionale di caratteri *ISO-8859-1* – che ha incluso ASCII di base e ASCII esteso – e il set di caratteri a 8 bit *Windows 1252* che nel corso dello sviluppo delle prime versioni di Windows si è andato differenziando dal precedente per i caratteri che vanno da `128` a `159`.

Conseguentemente si ha che nel set internazionale *ISO-8859-1* e nel set *Windows 1252*:
1) i caratteri che vanno da `0` a `127` (ASCII di base visti sopra) sono identici;
2) i caratteri da `128` a `159` nel set internazionale *ISO-8859-1* non sono stati codificati per evitare conflitti, mentre nel set *Windows 1252* sono codificati come segue

€ NC ‚ ƒ „ … † ‡ ˆ ‰ Š ‹ Œ NC Ž NC NC ‘ ’ “ ” • – — ˜™ š › œ NC ž Ÿ

(`NC` = carattere non codificato) e così rimarranno fino a quando Microsoft vorrà mantenere la compatibilità del suo set di caratteri (che viene denominato impropriamente *ANSI*) con le vecchie versioni di Windows;
3) i caratteri che vanno da `160` a `255` sono identici e sono codificati come segue

NBSP ¡ ¢ £ ¤ ¥ ¦ § ¨ © ª « ¬ SHY ® ¯ ° ± ² ³ ´ µ ¶ · ¸ ¹ º » ¼ ½ ¾ ¿ À Á Â Ã Ä Å Æ Ç
È É Ê Ë Ì Í Î Ï Ð Ñ Ò Ó Ô Õ Ö × Ø Ù Ú Û Ü Ý Þ ß à á â ã ä å æ ç è é ê ë ì í î ï ð ñ ò
ó ô õ ö ÷ ø ù ú û ü ý þ ÿ

Stante questo iniziale incidente di percorso, stante la vitale importanza di una codifica univoca dei caratteri e stante il numero elevato di caratteri da codificare (si pensi ad esempio al cirillico, al greco, all'aramaico, all'ebraico e al numero di ideogrammi necessari per codificare i testi in Cinese, Giapponese e Coreano) è nato quindi **Unicode**, un consorzio no-profit privato al quale partecipano

tutte le principali aziende di informatica, con lo scopo di assegnare ad ogni carattere impiegato per la scrittura un identificativo univoco indipendente dalla lingua, dalla piattaforma informatica e dal software impiegato [2].

Gli standard Unicode sono identificati dalla sigla **UTF** (Unicode Transformation Format) seguita da un numero progressivo di versione. Dal 1991 il Consorzio Unicode ha sviluppato gli standard in parallelo con la norma *ISO/IEC 10646* che definisce l'Universal Coded Character Set (**UCS**). Entrambi hanno lo stesso repertorio di caratteri, con gli stessi numeri: fortunatamente, saggiamente e forse è il caso di dire necessariamente, Unicode e ISO hanno deciso di normare congiuntamente in modo identico questo aspetto di base e così delicato della comunicazione.

Di fatto Unicode è oggi il riferimento ufficiale per la codifica dei caratteri – per definizione in linea con le norme ISO – e comprende:
→ i caratteri *ASCII di base* – ora inclusi nel set *Basic Latin* [3]
→ i caratteri *ASCII esteso* – ora inclusi nel set *Latin-1 Supplement* [4]
→ i caratteri (a fine 2025 poco meno di 160 000) che in aggiunta ai precedenti sono stati sviluppati per coprire tutte le lingue del mondo [5].

Attualmente il più estesamente impiegato è lo **standard UTF-8**: la stragrande maggioranza delle pagine web sono realizzate impiegando questo standard. Le varie versioni del *The Unicode® Standard* si possono trovare sul sito del consorzio [6].

---

[1] *ISO/IEC 646*.
https://en.wikipedia.org/wiki/ISO/IEC_646

[2] *The Unicode Consortium*.
https://home.unicode.org/

[3] *C0 Controls and Basic Latin*.
https://www.unicode.org/charts/PDF/U0000.pdf

[4] *C1 Controls and Latin-1 Supplement*.
https://www.unicode.org/charts/PDF/U0080.pdf

[5] *Unicode Character Code Charts*.
https://www.unicode.org/charts/

[6] *Enumerated Versions of The Unicode® Standard*.
https://www.unicode.org/versions/enumeratedversions.html